

Análisis de Calidad de Servicio en Infraestructura On-Premise mediante Simulación Evento a Evento

Magnarelli U., Martín L., Duarte G., Cacace F.

Universidad Tecnológica Nacional,
Facultad Regional Buenos Aires

Abstract

El presente trabajo modela y simula una infraestructura de red on-premise¹ con el objetivo de analizar la configuración óptima de servidores para el puerto crítico, empleando la metodología de Simulación Evento a Evento (EaE) sobre datos reales del dataset CICDarknet2020 (6.308 registros). Se ajustaron distribuciones estadísticas —Kappa3 para el intervalo de arribo y Lomax para el tiempo de atención— y se construyó un simulador con dos clases de servidores, prioridad de protocolo UDP sobre TCP, arrepentimiento probabilístico y timeout fijo de 5.000 ms. Se evaluaron cinco escenarios de inversión con un presupuesto máximo de cuatro servidores adicionales. La configuración $N=2$, $M=3$ resultó óptima: reduce los flujos descartados del 49% al 8% y el tiempo de espera promedio de 1.210 ms a 338 ms con una inversión de tres servidores adicionales.

Palabras clave

Simulación Evento a Evento, QoS, balanceo de carga, colas con prioridad, CICDarknet2020, distribución Kappa3, distribución Lomax, timeout, arrepentimiento.

1. Introducción

El crecimiento sostenido del tráfico de red en entornos on-premise genera presión sobre la infraestructura de servidores, derivando en saturación y pérdida de paquetes. La empresa objeto de estudio requiere evaluar si la situación actual amerita inversión en hardware adicional o si una reconfiguración de la lógica de

despacho puede resolver el cuello de botella.

El desafío consiste en garantizar la Calidad de Servicio (QoS) sobre el puerto 51413, que concentra flujos UDP (85% del tráfico, tiempo-sensible) y TCP (15%, con mecanismos de retransmisión). El presupuesto disponible equivale a cuatro servidores adicionales, con un costo estimado de 4.000.000 de pesos.

Para responder esta pregunta de negocio se empleó la Simulación Evento a Evento (EaE), metodología que permite experimentar con múltiples configuraciones de hardware sin incurrir en costos reales, basándose en datos empíricos del comportamiento real del sistema [1].

2. Elementos del Trabajo y Metodología

2.1 Simulación Evento a Evento. En la metodología EaE el reloj del sistema avanza directamente al instante del próximo evento programado, sin procesar instantes intermedios. Esto la hace eficiente para sistemas con eventos esporádicos o intervalos variables, como el tráfico de red [1].

El motor EaE opera mediante dos estructuras. La Tabla de Eventos Independientes (TEI) es un mapa estático que define, para cada evento, qué eventos futuros genera: el Evento Futuro No Condicionado (EFNC), que ocurre siempre, y el Evento Futuro Condicionado (EFC), que ocurre solo si el estado del sistema satisface una condición. La Tabla de Eventos Futuros (TEF) es la agenda dinámica que registra los eventos pendientes con su tiempo simulado.

Una propiedad fundamental es que el tiempo simulado permanece estático entre eventos: toda la lógica de procesamiento ocurre en el instante T del evento, sin

¹ **On-premise:** Referencia a que la infraestructura se aloja localmente en la empresa

avance del reloj durante la ejecución del código.

2.2 Clasificación de variables. Para asegurar la validez metodológica del modelo de simulación y permitir la correcta evaluación de la Calidad de Servicio (QoS), el sistema se define a partir de las siguientes variables, las cuales interactúan a lo largo de la simulación:

Variables Exógenas:

a. Datos:

-IA (Intervalo de Arribo): Variable aleatoria continua que modela el tiempo entre llegadas de nuevos flujos. Ajustada a una Función de Densidad de Probabilidad (FDP) Kappa3.

-TA_UDP/TA_TCP (Tiempo de Atención): Variable aleatoria continua que define el tiempo de servicio requerido por flujo. Ajustada a una FDP Lomax, con un tope o clip en el P95 (10.000 ms) para acotar la cola pesada (heavy-tail).

b. Variable de Control:

-N: Cantidad de Servidores de Clase A (Exclusivos para el protocolo prioritario UDP).

-M: Cantidad de Servidores de Clase B (Generales, procesan TCP y UDP).

Variables Endógenas:

a. Variable de Estado:

-CU: Cantidad de flujos de protocolo UDP esperando en cola.

-CT: Cantidad de flujos de protocolo TCP esperando en cola.

-CSA: Cantidad de Servidores Clase A ocupados.

-CSB: Cantidad de Servidores Clase B ocupados.

b. Variable de Resultado:

-PEC_U: Promedio de espera en cola de los flujos UDP.

-PEC_T: Promedio de espera en cola de los flujos TCP.

-PTO_A (I): Porcentaje de tiempo ocioso de cada servidor Clase A.

-PTO_B (I): Porcentaje de tiempo ocioso de cada servidor Clase B.

-NTU: Cantidad total de flujos UDP atendidos.

-NTT: Cantidad total de flujos TCP atendidos.

-PAT: Porcentaje de Flujos totales arrepentidos TCP respecto a los que no se arrepienten.

2.3 Tabla de Eventos Independientes. La TEI del sistema modela cuatro tipos de eventos:

Tabla 1. Tabla de Eventos Independientes (TEI)

Evento	EFNC	EFC	Condición
Llegada	Llegada	SalidaA (i)	$CU \geq 1$ y $CSA < N$
		SalidaB (i)	$(CU \geq 1, CSA = N, CSB < M)$ OR $(CT \geq 1, CU = 0, CSB < M)$
SalidaA (i)	—	SalidaA (i)	$CU > 0$
SalidaB (i)	—	SalidaB (i)	$CU \geq 2$ OR $(CT \geq 1$ y $CU \leq 1)$


La Llegada genera siempre otra Llegada (EFNC), garantizando la continuidad del flujo de eventos. Las salidas no tienen

EFNC porque la liberación de un servidor solo genera un nuevo evento de servicio si existe demanda pendiente.

2.4 Arrepentimiento. Antes de ingresar, cada flujo evalúa la carga del sistema. Si está saturado, decide no entrar con probabilidad creciente: 0% si hay ≤ 100 flujos activos, 30% entre 101 y 300, 80% entre 301 y 500, y 100% si supera los 500 flujos. Los flujos rechazados por arrepentimiento se contabilizan en la variable PAT [1].


2.5 Timeout. El timeout (TO=5.000 ms) define el tiempo máximo que un flujo espera en cola antes de descartarse, en analogía con el TTL de los paquetes de red. Se implementa con dos mecanismos: una limpieza proactiva que purga toda la cola al liberar un servidor, y una verificación individual sobre el flujo a asignar. Ambos mecanismos contabilizan los flujos expirados en el mismo contador [1].

2.6 Dataset y distribuciones. Se utilizaron 6.308 registros del dataset CICDarknet2020 correspondientes al puerto crítico. Para el intervalo de arribo (IA) se ajustó una distribución Kappa3 ($a=1,93$, $scale \times 3$, media $\approx 1,3$ seg).



Para el tiempo de atención (TA) se ajustó una distribución Lomax ($c=0,264$, $scale=116,75$ ms, mediana $\approx 1,5$ seg) con

clip en el P95 del dataset (10.000 ms) para evitar valores extremos de la heavy-tail [1].



Durante el desarrollo se identificó y corrigió un error crítico: el Flow Duration del dataset está en microsegundos. El notebook de preparación los convierte a milisegundos ($\div 1.000$) antes del ajuste, por lo que los parámetros ya están en milisegundos. El simulador original volvía a multiplicar por 1.000, generando tiempos de atención de horas y colapso del sistema. Se eliminó dicho factor y se aplicó el clip mencionado.

2.7 Criterio de parada. El simulador corre 6.000 iteraciones (aproximadamente 2h) de eventos por corrida. Este criterio garantiza que todos los escenarios procesen la misma cantidad de eventos, haciendo la comparación entre configuraciones equitativa. Dado que el IA promedio es de ~ 1.300 ms, el tiempo simulado resultante equivale aproximadamente a dos horas de tráfico real[1].

3. Resultados

Se ejecutaron cinco escenarios variando N (servidores Clase A, exclusivos UDP) y M (servidores Clase B, generales TCP/UDP) dentro del presupuesto de cuatro unidades adicionales.

Tabla 2. Resultados comparativos por escenario

Config.	% Desc.	Esp. A (ms)	Esp. B (ms)	% Ocio
N=1,M=1	49%	1.210	980	20%
N=1,M=2	36%	8.400	620	5%
N=1,M=3	8%	1.163	285	18%
N=2,M=3	8%	338	210	35%
N=1,M=5	5%	283	95	40%

Escenario 1 (N=1,M=1): El sistema descarta el 49% del tráfico. La saturación es total: la empresa pierde la mitad de la capacidad de procesamiento.

Escenario 2 (N=1,M=2): Paradójicamente, la espera en A sube a 8.400 ms. Al agregar un servidor B, más flujos TCP pasan el arrepentimiento y saturan el único servidor A, profundizando el cuello de botella.

Escenario 3 (N=1,M=3): Primer escenario sin rechazo por saturación. Los flujos descartados (8%) corresponden únicamente a timeout. Es la inversión mínima viable.

Escenario 4 (N=2,M=3): El servidor A adicional descomprime el protocolo prioritario. La espera cae a 338 ms en A y 210 ms en B. El 35% de tiempo ocioso representa capacidad de absorción ante picos de tráfico.

Escenario 5 (N=1,M=5): Mejora marginal sobre el Escenario 4 (3 pp en descartados, 55 ms en espera A) con un servidor adicional. La ley de rendimientos decrecientes opera claramente.

4. Discusión

Los resultados evidencian que el problema del sistema actual no es solo de cantidad de servidores sino de distribución entre clases. El escenario 2 demuestra que agregar servidores B sin reforzar A puede empeorar la percepción de rendimiento: más flujos acceden al sistema pero encuentran un cuello de botella más pronunciado en el único servidor UDP.

La comparación entre escenarios 4 y 5 ilustra el principio de rendimientos decrecientes en la inversión en infraestructura: el cuarto servidor adicional produce mejoras de 3 puntos porcentuales en flujos descartados y 55 ms en tiempo de espera, frente a la mejora de 41 puntos porcentuales que produce el paso del escenario 1 al escenario 3.

El 8% de flujos con timeout en el mejor escenario no representa una falla del modelo sino el comportamiento esperado ante la variabilidad inherente del tráfico: picos momentáneos cuya duración supera los 5 segundos de TTL configurado. Reducir ese porcentaje requeriría aumentar el TO o dimensionar para el peor caso, ambas opciones con sus propias implicancias de negocio.

5. Conclusión

La simulación EaE permitió evaluar cinco configuraciones de inversión en hardware sin costo real, determinando que N=2, M=3 —tres servidores adicionales— constituye el punto sugerido dentro del presupuesto disponible.

La configuración recomendada reduce los flujos descartados en un 83% (de 49% a 8%), el tiempo de espera promedio en el servidor A en un 72% (de 1.210 ms a 338 ms) y en el servidor B en un 79% (de 980 ms a 210 ms), con un 35% de tiempo

ocioso que garantiza capacidad de respuesta ante variaciones de la demanda.

Se recomienda incorporar un servidor Clase A y dos servidores Clase B. La inversión del cuarto servidor (Escenario 5) no se justifica dado el retorno marginal obtenido respecto al Escenario 4.

Referencias

[1] Apuntes de la cátedra de Simulación — Metodología Evento a Evento, clasificación de variables, sistemas de colas con prioridad y arrepentimiento. UTN Facultad Regional Buenos Aires.

Datos de Contacto

Ulises Magnarelli. UTN FRBA. Buenos Aires, Argentina.

Lucas Martin. UTN FRBA. Buenos Aires, Argentina.

Gonzalo Duarte. UTN FRBA. Buenos Aires, Argentina.

Federico Cacace. UTN FRBA. Buenos Aires, Argentina.